Caracterização de desempenho em aprendizado de máquina e operações de armazenamento: comparação entre baseline (sem) e Protected (com Bitdefender)

1 Introdução e objetivo

O tempo de execução de uma aplicação de aprendizado de máquina depende tanto do processamento numérico quanto das etapas que fornecem dados e preservam o estado do modelo. A inicialização do ambiente, o carregamento dos conjuntos de dados e a gravação de checkpoints podem acrescentar tempo a uma rotina mesmo quando o treinamento utiliza aceleração gráfica. Avaliar essas etapas separadamente permite localizar diferenças que uma única medida de duração total ocultaria.

A presença de uma solução de segurança constitui uma possível fonte de competição por recursos e de trabalho adicional nas operações de entrada e saída. Essa possibilidade motiva a análise de uma máquina com Bitdefender em relação a uma máquina declarada sem o produto. O problema experimental consiste em distinguir as diferenças observadas entre ambientes de uma contribuição específica do mecanismo de proteção.

Este relatório apresenta uma comparação descritiva entre baseline (sem Bitdefender) e Protected (com Bitdefender). São examinados inicialização, treinamento, computação matricial, carregamento de dados, operações de armazenamento, checkpoints de modelos e consumo dos componentes do Bitdefender. As tabelas incluem as métricas temporais e de taxa de processamento disponíveis nas duas condições, com resultados favoráveis e desfavoráveis à condição Protected (com).

O objetivo é quantificar as diferenças por tarefa e discutir seu significado operacional, mantendo as unidades próprias de cada ensaio.

2 Metodologia e condições experimentais

2.1 Ambientes de execução

Foram consideradas duas sessões de execução, uma por condição: baseline (sem Bitdefender) e Protected (com Bitdefender). A caracterização dos ambientes é apresentada na Tabela 1. Em ambos os ambientes foi selecionada uma GeForce RTX 4070.

Tabela 1: Características dos ambientes de execução. Ambas as máquinas possuem 64 GB de memória instalada.

Característica	Condição baseline (sem)	Condição Protected (com)
Processador	Intel Xeon Silver 4316	Intel Xeon Gold 5220
Memória instalada	64 GB	64 GB
Sistema operacional	Linux, Ubuntu	Linux, Ubuntu
Python do controlador	3.13.0	3.12.3
PyTorch / torchvision	2.14.1 / 0.29.1	2.14.1 / 0.29.1
TensorFlow	2.21.0	2.21.0
Acelerador selecionado	GeForce RTX 4070	GeForce RTX 4070
Driver NVIDIA	595.99.02	595.99.02

Foram observados componentes do Bitdefender em Protected (com) e nenhum componente correspondente em baseline (sem) durante a caracterização inicial. A consulta do estado de proteção

permaneceu indeterminada nos dois ambientes. A identificação das condições segue, assim, a declaração experimental e a presença observada dos componentes, sem equivaler à verificação integral da política de proteção.

2.2 Cargas e procedimento

As cargas abrangeram perceptron multicamadas (MLP), rede neural convolucional (CNN), Transformer, ResNet-18, multiplicação de matrizes e estimadores do scikit-learn. Foram empregados dados gerados, CIFAR-10 e WikiText-2 na variante raw-v1. As identidades de conteúdo registradas para os conjuntos públicos coincidiram entre as condições, assim como os parâmetros das cargas correspondentes e os metadados de execução dos resultados selecionados.

Os ensaios selecionados de treinamento em PyTorch e TensorFlow utilizaram 200 passos medidos, precedidos por cinco passos de aquecimento, em precisão de ponto flutuante de 32 bits. O tamanho de lote foi 32 nos casos selecionados de dados gerados e CIFAR-10, e 16 no modelo de linguagem com WikiText-2 raw-v1. A semente fixada foi 1234. Esses parâmetros definem trabalho fixo, de modo que as diferenças de tempo não correspondem a critérios diferentes de parada por convergência.

Os tempos de treinamento foram delimitados após a preparação dos dados e separados das medidas de carregamento. As execuções aceleradas empregaram sincronização nos limites de cronometragem. As rotinas de inicialização distinguiram importação do ambiente, inicialização do dispositivo e primeiro passo de treinamento. As operações de armazenamento incluíram leituras aleatórias, manipulação de pequenos arquivos, remoção de metadados e uma operação de controle de checkpoint. As rotinas de checkpoint de modelos distinguiram gravação com e sem sincronização persistente e preservaram o estado do modelo e do otimizador.

Cada métrica tabulada reúne três observações concluídas em cada condição. Tentativas com falha foram excluídas, assim como registros com aviso ou contaminação. As duas sessões parciais adicionais da máquina baseline (sem) não foram agregadas à sessão utilizada, preservando uma sessão por condição. A análise apresenta os pares de métricas temporais e de taxa de processamento disponíveis em ambas as condições, sem agregar grandezas de unidades diferentes em uma pontuação global.

2.3 Estatísticas e interpretação

Para cada tarefa, são apresentadas a mediana e o desvio-padrão amostral das três repetições. O desvio-padrão caracteriza a dispersão dos valores individuais, não a incerteza de um efeito entre máquinas. A notação mediana ± desvio-padrão nas tabelas não designa um intervalo de confiança.

A variação descritiva foi calculada por

$$\Delta = 100 \left(\frac{m_{\text{Protected}}}{m_{\text{baseline}}} - 1 \right), \tag{1}$$

em que m_{baseline} e $m_{\text{Protected}}$ são as medianas da métrica nas respectivas condições. Para durações, $\Delta > 0$ indica maior tempo em Protected (com). Para taxas de processamento, $\Delta < 0$ indica redução em Protected (com). A redução percentual da taxa corresponde, portanto, a $-\Delta$. A cor vermelha indica piora de Protected (com) em relação ao baseline (sem), e a verde indica melhora. Para duração, valores menores são melhores. Para taxa, valores maiores são melhores. O sinal do percentual é mantido e a cor representa o sentido de desempenho, não o sinal aritmético.

As unidades observacionais são repetições dentro de uma sessão. Não foram calculados intervalos de efeito entre condições, pois uma sessão por condição não caracteriza a variação entre sessões. Além disso, os processadores diferem. Os percentuais devem ser interpretados como razões entre medições desses ambientes, sem atribuição exclusiva ao Bitdefender.

2.4 Caracterização dos processos do Bitdefender

O consumo do agente foi analisado em duas escalas: observações históricas em 7 e 28 de outubro de 2026 e observações durante as execuções concluídas do benchmark em 3 de novembro de 2026. As janelas históricas foram tratadas separadamente da campanha de desempenho. O monitoramento histórico reuniu cinco sessões, com intervalo nominal de dois segundos, totalizando 36,82 minutos efetivamente amostrados.

Nas medições de processamento do agente, 100% corresponde à ocupação de um processador lógico. A média de utilização foi ponderada pela duração efetiva dos intervalos, e os picos correspondem ao maior intervalo amostrado. Para os componentes durante o benchmark, o uso foi calculado pela diferença do tempo acumulado em modo usuário e sistema entre observações consecutivas do mesmo processo, identificado também pelo instante de criação. Não foram conectados intervalos entre execuções distintas. As janelas abrangem o ciclo de vida das execuções, incluindo preparação e aquecimento, e não apenas a fronteira cronometrada do treinamento.

A memória residente corresponde às páginas residentes atribuídas aos processos. A memória contabilizada por serviço inclui memória anônima, cache de arquivos e alocações do kernel. As médias de memória são médias das amostras, enquanto as taxas de leitura e gravação foram integradas pela duração dos intervalos. As unidades MiB e GiB correspondem, respectivamente, a 2^{20} e 2^{30} bytes.

3 Resultados de treinamento e computação

3.1 Inicialização do ambiente

A inicialização do PyTorch na unidade central de processamento (CPU) apresentou mediana de 0,7451 s em baseline (sem) e 1,2106 s em Protected (com), uma diferença de 62,49%. O primeiro passo de treinamento passou de 0,0235 s para 0,0492 s, correspondendo a 109,81% de aumento. A importação do mesmo ambiente apresentou diferença menor, de 2,06%. Essas três medidas representam etapas distintas. A mediana da duração total de uma execução não é obtida pela soma das medianas de suas etapas.

A Tabela 2 também apresenta os casos selecionados do TensorFlow. A diferença da importação na CPU foi de 0,27%, enquanto a inicialização apresentou aumento de 15,71%. Na unidade de processamento gráfico (GPU), a importação apresentou aumento de 15,91%. A dispersão elevada da inicialização do PyTorch em Protected (com), em relação à sua mediana, recomenda interpretar a diferença como descrição das repetições observadas, sem tratá-la como uma penalidade fixa por inicialização.

Tabela 2: Inicialização dos ambientes. Três observações por métrica e condição. Vermelho indica piora e verde indica melhora em relação ao baseline (sem).

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
Inicialização PyTorch, CPU	Importação	s	1,3794 ± 0,1703	1,4079 ± 1,4308	+2,06
Inicialização PyTorch, CPU	Inicialização	s	0,7451 ± 0,0182	1,2106 ± 1,9162	+62,49
Inicialização PyTorch, CPU	Primeiro passo	s	0,0235 ± 0,0009	0,0492 ± 0,0037	+109,81
Inicialização TensorFlow, CPU	Importação	s	1,9261 ± 0,2987	1,9314 ± 0,0463	+0,27
Inicialização TensorFlow, CPU	Inicialização	s	0,0887 ± 0,0241	0,1026 ± 0,0024	+15,71
Inicialização TensorFlow, CPU	Primeiro passo	s	0,4640 ± 0,0944	0,4052 ± 0,0064	-12,66
Inicialização PyTorch, GPU†	Importação	s	1,5678 ± 0,0422	1,4207 ± 0,0237	-9,38
Inicialização PyTorch, GPU†	Inicialização	s	1,4516 ± 0,2815	1,3549 ± 0,0293	-6,66
Inicialização PyTorch, GPU†	Primeiro passo	s	0,1871 ± 0,0456	0,1834 ± 0,0037	-1,99

Continua na próxima página

Tabela 2 – continuação

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
Inicialização TensorFlow, GPU†	Importação	s	1,7152 ± 0,3047	1,9880 ± 0,0679	+15,91
Inicialização TensorFlow, GPU†	Inicialização	s	1,3862 ± 0,1360	1,3220 ± 0,0635	-4,63
Inicialização TensorFlow, GPU†	Primeiro passo	s	1,4342 ± 0,1325	1,1927 ± 0,0411	-16,84

† A indicação de GPU identifica o dispositivo selecionado. O tempo também depende do hospedeiro, da alimentação dos dados e das condições do acelerador. Verde indica melhor desempenho observado de Protected (com), não aceleração causada pelo Bitdefender.

O primeiro passo de treinamento do TensorFlow em CPU apresentou redução de 12,66%. Na GPU, a importação do PyTorch apresentou redução de 9,38%, e o primeiro passo do TensorFlow apresentou redução de 16,84%. As melhoras e pioras da Tabela 2 correspondem a etapas distintas, preservadas separadamente na análise.

3.2 Treinamento e computação em processador

Nos dados gerados com PyTorch, a CNN apresentou duração de 0,9666 s no baseline (sem) e 1,7060 s em Protected (com), um aumento de 76,48%. A taxa correspondente passou de 6620,8546 para 3751,5315 amostras/s, uma redução de 43,34%. O MLP e o Transformer apresentaram aumentos de duração de 60,75% e 62,52%, respectivamente, acompanhados de reduções de taxa de 37,79% e 38,47%.

A multiplicação de matrizes em PyTorch apresentou duração 89,01% maior e taxa 47,09% menor em Protected (com). No TensorFlow, a mesma categoria de operação apresentou duração 45,83% maior e taxa 31,43% menor. A Tabela 3 apresenta os resultados por carga, sem estabelecer uma classificação geral entre bibliotecas.

Com CIFAR-10, a CNN em PyTorch apresentou duração 55,78% maior em Protected (com), enquanto a ResNet-18 apresentou aumento de 11,79%. No Transformer de linguagem com WikiText-2 raw-v1, a duração passou de 13,8190 s para 15,5368 s, uma diferença de 12,43%. No scikit-learn, os aumentos de duração foram de 51,00% na regressão logística, 20,39% no boosting por histogramas e 7,62% na floresta aleatória.

No TensorFlow em CPU, também foram observadas melhoras: a duração do MLP com dados gerados diminuiu 48,72%, a da CNN diminuiu 52,55% e a do Transformer de linguagem com WikiText-2 raw-v1 diminuiu 24,31%. O sentido das diferenças depende, portanto, da carga e do ambiente de execução.

3.3 Computação acelerada

A execução em GPU combina operações no acelerador com trabalho do hospedeiro, como despacho das operações e sincronização. O carregamento dos dados foi medido separadamente do treinamento, de modo que a duração tabulada do treinamento não inclui automaticamente toda a leitura do conjunto de dados. Mesmo com dados residentes, a execução mantém etapas no hospedeiro e no acelerador, cujas condições podem alterar o tempo observado. A utilização do mesmo modelo de placa, portanto, não torna os dois ambientes equivalentes.

As linhas identificadas por † nas tabelas correspondem a ensaios com GPU selecionada. As melhoras nesses ensaios descrevem o desempenho observado de Protected (com). Elas não demonstram que o Bitdefender acelerou o treinamento nem permitem quantificar qual condição de execução produziu o ganho.

O caso de multiplicação de matrizes em GPU, com PyTorch, apresentou aumento de duração de 0,37% e redução de taxa de 0,37%. A magnitude pequena dessa diferença deve orientar sua interpretação, sem pressupor significância estatística.

Nos casos acelerados com PyTorch, as durações da CNN e da ResNet-18 com CIFAR-10 diminuíram 25,76% e 26,74%, respectivamente. No Transformer de linguagem com WikiText-2 raw-v1, a duração diminuiu 40,93%. Com TensorFlow e CIFAR-10, a CNN apresentou redução de duração de 52,23%. Essas melhoras coexistem com as pioras descritas e estão incluídas na Tabela 3.

Tabela 3: Treinamento e computação. Três observações por métrica e condição. Vermelho indica piora e verde indica melhora em relação ao baseline (sem).

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
MLP PyTorch, CPU Dados gerados	Duração	s	0,1633 ± 0,0387	0,2626 ± 0,0149	+60,75
MLP PyTorch, CPU Dados gerados	Taxa	amostras/s	39180,5208 ± 6918,7577	24373,4754 ± 1288,2193	-37,79
CNN PyTorch, CPU Dados gerados	Duração	s	0,9666 ± 0,0773	1,7060 ± 0,1998	+76,48
CNN PyTorch, CPU Dados gerados	Taxa	amostras/s	6620,8546 ± 466,8710	3751,5315 ± 531,5943	-43,34
Transformer PyTorch, CPU Dados gerados	Duração	s	2,6993 ± 0,0795	4,3868 ± 0,2076	+62,52
Transformer PyTorch, CPU Dados gerados	Taxa	amostras/s	2371,0142 ± 67,9688	1458,9113 ± 74,9503	-38,47
Matrizes PyTorch, CPU Dados gerados	Duração	s	0,3249 ± 0,0485	0,6141 ± 0,0494	+89,01
Matrizes PyTorch, CPU Dados gerados	Taxa	GFLOP/s	1321,9155 ± 213,8778	699,3902 ± 53,4200	-47,09
CNN PyTorch, CPU CIFAR-10	Duração	s	1,2428 ± 0,0656	1,9360 ± 0,1963	+55,78
CNN PyTorch, CPU CIFAR-10	Taxa	amostras/s	5149,7054 ± 281,8578	3305,8014 ± 395,9982	-35,81
ResNet-18 PyTorch, CPU CIFAR-10	Duração	s	9,4812 ± 0,2587	10,5986 ± 0,2576	+11,79
ResNet-18 PyTorch, CPU CIFAR-10	Taxa	amostras/s	675,0188 ± 17,9765	603,8540 ± 14,6947	-10,54
Transformer de linguagem PyTorch, CPU WikiText-2 raw-v1	Duração	s	13,8190 ± 0,4633	15,5368 ± 0,3234	+12,43

Continua na próxima página

Tabela 3 – continuação

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
Transformer de linguagem PyTorch, CPU WikiText-2 raw-v1	Taxa	tokens/s	7410,1043 ± 262,2953	6590,8220 ± 136,0242	-11,06
MLP TensorFlow, CPU Dados gerados	Duração	s	0,5420 ± 0,0574	0,2780 ± 0,0045	-48,72
MLP TensorFlow, CPU Dados gerados	Taxa	amostras/s	11807,0872 ± 1464,7314	23022,6038 ± 368,8904	+94,99
CNN TensorFlow, CPU Dados gerados	Duração	s	1,5161 ± 0,3640	0,7194 ± 0,0066	-52,55
CNN TensorFlow, CPU Dados gerados	Taxa	amostras/s	4221,2513 ± 1687,8585	8896,1380 ± 82,1178	+110,75
Transformer TensorFlow, CPU Dados gerados	Duração	s	0,7624 ± 0,0322	0,5897 ± 0,0039	-22,66
Transformer TensorFlow, CPU Dados gerados	Taxa	amostras/s	8394,2491 ± 345,9508	10853,3689 ± 71,3327	+29,30
Matrizes TensorFlow, CPU Dados gerados	Duração	s	0,5548 ± 0,0980	0,8090 ± 0,0341	+45,83
Matrizes TensorFlow, CPU Dados gerados	Taxa	GFLOP/s	774,1924 ± 183,7001	530,8768 ± 24,0264	-31,43
CNN TensorFlow, CPU CIFAR-10	Duração	s	0,7010 ± 0,0545	0,7740 ± 0,0076	+10,42
CNN TensorFlow, CPU CIFAR-10	Taxa	amostras/s	9130,0905 ± 630,4345	8268,4604 ± 81,2079	-9,44
Transformer de linguagem TensorFlow, CPU WikiText-2 raw-v1	Duração	s	8,3546 ± 0,0880	6,3236 ± 0,1254	-24,31
Transformer de linguagem TensorFlow, CPU WikiText-2 raw-v1	Taxa	tokens/s	12256,6653 ± 130,4069	16193,2743 ± 327,5523	+32,12
MLP PyTorch, GPU† Dados gerados	Duração	s	0,2180 ± 0,0475	0,1555 ± 0,0026	-28,67
MLP PyTorch, GPU† Dados gerados	Taxa	amostras/s	29358,8294 ± 4779,0746	41159,1838 ± 667,5296	+40,19

Continua na próxima página

Tabela 3 – continuação

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
CNN PyTorch, GPU† Dados gerados	Duração	s	0,3523 ± 0,0765	0,2356 ± 0,0004	-33,13
CNN PyTorch, GPU† Dados gerados	Taxa	amostras/s	18168,2720 ± 3293,7492	27167,7727 ± 45,3715	+49,53
Transformer PyTorch, GPU† Dados gerados	Duração	s	1,5087 ± 0,0105	0,8708 ± 0,0244	-42,28
Transformer PyTorch, GPU† Dados gerados	Taxa	amostras/s	4241,9940 ± 29,7704	7349,5100 ± 199,4001	+73,26
Matrizes PyTorch, GPU† Dados gerados	Duração	s	0,0259 ± $2,85520 \times 10^{-5}$	0,0260 ± 0,0001	+0,37
Matrizes PyTorch, GPU† Dados gerados	Taxa	GFLOP/s	16583,8259 ± 18,2549	16522,2639 ± 92,7639	-0,37
CNN PyTorch, GPU† CIFAR-10	Duração	s	1,1433 ± 0,0854	0,8488 ± 0,0213	-25,76
CNN PyTorch, GPU† CIFAR-10	Taxa	amostras/s	5597,8910 ± 394,9802	7540,2048 ± 197,4874	+34,70
ResNet-18 PyTorch, GPU† CIFAR-10	Duração	s	2,8139 ± 0,1328	2,0616 ± 0,0186	-26,74
ResNet-18 PyTorch, GPU† CIFAR-10	Taxa	amostras/s	2274,4011 ± 115,1220	3104,4484 ± 27,8746	+36,50
Transformer de linguagem PyTorch, GPU† WikiText-2 raw-v1	Duração	s	1,5802 ± 0,0342	0,9334 ± 0,0125	-40,93
Transformer de linguagem PyTorch, GPU† WikiText-2 raw-v1	Taxa	tokens/s	64800,0551 ± 1367,4515	109704,9015 ± 1438,2984	+69,30
Regressão logística scikit-learn, CPU Dados gerados	Duração	s	0,1949 ± 0,0145	0,2944 ± 0,1225	+51,00
Boosting por histogramas scikit-learn, CPU Dados gerados	Duração	s	0,4501 ± 0,0210	0,5419 ± 0,0408	+20,39
Floresta aleatória scikit-learn, CPU Dados gerados	Duração	s	4,0307 ± 0,0401	4,3377 ± 0,0283	+7,62

Continua na próxima página

Tabela 3 – continuação

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
MLP TensorFlow, GPU† Dados gerados	Duração	s	0,4775 ± 0,0401	0,2118 ± 0,0189	-55,65
MLP TensorFlow, GPU† Dados gerados	Taxa	amostras/s	13403,4292 ± 1284,3200	30222,0731 ± 2364,9431	+125,48
CNN TensorFlow, GPU† Dados gerados	Duração	s	0,6857 ± 0,0196	0,3567 ± 0,0067	-47,97
CNN TensorFlow, GPU† Dados gerados	Taxa	amostras/s	9333,7914 ± 262,8731	17940,5223 ± 345,9178	+92,21
Transformer TensorFlow, GPU† Dados gerados	Duração	s	0,8552 ± 0,0220	0,4475 ± 0,0134	-47,67
Transformer TensorFlow, GPU† Dados gerados	Taxa	amostras/s	7483,6020 ± 185,5018	14300,8190 ± 415,2757	+91,10
Matrizes TensorFlow, GPU† Dados gerados	Duração	s	0,0226 ± 0,0001	0,0204 ± 0,0001	-9,71
Matrizes TensorFlow, GPU† Dados gerados	Taxa	GFLOP/s	19040,1142 ± 44,3522	21087,1813 ± 101,6693	+10,75
CNN TensorFlow, GPU† CIFAR-10	Duração	s	0,8264 ± 0,0041	0,3948 ± 0,0101	-52,23
CNN TensorFlow, GPU† CIFAR-10	Taxa	amostras/s	7744,4914 ± 38,4644	16212,1489 ± 417,3499	+109,34
Transformer de linguagem TensorFlow, GPU† WikiText-2 raw-v1	Duração	s	1,0821 ± 0,0307	0,7342 ± 0,0062	-32,15
Transformer de linguagem TensorFlow, GPU† WikiText-2 raw-v1	Taxa	tokens/s	94629,8287 ± 2778,2957	139470,8167 ± 1174,2094	+47,39

† A indicação de GPU identifica o dispositivo selecionado. O tempo também depende do hospedeiro, da alimentação dos dados e das condições do acelerador. Verde indica melhor desempenho observado de Protected (com), não aceleração causada pelo Bitdefender.

4 Carregamento, checkpoints e operações de arquivos

4.1 Carregamento dos conjuntos de dados

O carregamento do CIFAR-10 apresentou maior duração em Protected (com) nos casos de PyTorch. Para a CNN em CPU, a mediana passou de 0,4426 s para 0,5160 s, correspondendo a 16,57%. Para a ResNet-18 em CPU, a diferença foi de 10,30%. Nos casos vinculados à GPU, os aumentos foram de 7,46% e 6,97%, respectivamente, conforme a Tabela 4.

Para o TensorFlow, o carregamento do CIFAR-10 apresentou redução de duração de 15,63%

no caso associado à CPU e de 34,48% no caso associado à GPU. O sentido oposto ao observado no PyTorch reforça a necessidade de manter as rotinas de carregamento separadas por ambiente.

A existência de uma GPU selecionada não elimina o processamento no hospedeiro necessário para preparar os dados. Esses tempos pertencem à etapa de carregamento e são distintos da duração medida do treinamento. Sua diferença percentual não deve ser transferida diretamente para o tempo de treinamento ou para o desempenho global de uma aplicação.

Tabela 4: Carregamento de dados. Três observações por métrica e condição. Vermelho indica piora e verde indica melhora em relação ao baseline (sem).

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
CNN PyTorch, CPU CIFAR-10	Carregamento	s	0,4426 ± 0,0033	0,5160 ± 0,0593	+16,57
ResNet-18 PyTorch, CPU CIFAR-10	Carregamento	s	0,4444 ± 0,0043	0,4902 ± 0,0051	+10,30
CNN TensorFlow, CPU CIFAR-10	Carregamento	s	1,5214 ± 0,2948	1,2836 ± 0,0491	-15,63
CNN PyTorch, GPU† CIFAR-10	Carregamento	s	0,4432 ± 0,0012	0,4763 ± 0,0025	+7,46
ResNet-18 PyTorch, GPU† CIFAR-10	Carregamento	s	0,4687 ± 0,1482	0,5014 ± 0,0128	+6,97
CNN TensorFlow, GPU† CIFAR-10	Carregamento	s	2,0978 ± 0,0241	1,3745 ± 0,0178	-34,48

† A indicação de GPU identifica o dispositivo selecionado. O tempo também depende do hospedeiro, da alimentação dos dados e das condições do acelerador. Verde indica melhor desempenho observado de Protected (com), não aceleração causada pelo Bitdefender.

4.2 Operações de armazenamento

A manipulação de pequenos arquivos passou de 0,0407 s no baseline (sem) para 0,1174 s em Protected (com), um aumento de 188,63%. A taxa correspondente diminuiu 65,35%. Na remoção de metadados, o aumento de duração foi de 148,00% e a redução de taxa foi de 59,68%.

As leituras aleatórias apresentaram duração 96,40% maior e taxa 49,08% menor. A operação de controle de checkpoint apresentou duração 200,85% maior e taxa 66,76% menor, conforme a Tabela 5. Esse controle é distinto da serialização do estado de um modelo. Embora seus percentuais sejam elevados, os tempos absolutos permanecem na ordem de centésimos ou décimos de segundo nessas execuções.

As operações sequenciais apresentaram redução de duração de 7,47%, enquanto a gravação de escalares apresentou redução de 5,66%. Logo, a piora nas operações de pequenos arquivos não se estendeu uniformemente a todas as operações de armazenamento.

Tabela 5: Operações de armazenamento. Três observações por métrica e condição. Vermelho indica piora e verde indica melhora em relação ao baseline (sem).

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
Leitura e gravação sequenciais Armazenamento	Duração	s	0,0319 ± 0,0020	0,0295 ± 0,0021	-7,47
Leitura e gravação sequenciais Armazenamento	Taxa	bytes/s	$4,21323 \times 10^9$ ± $2,61725 \times 10^8$	$4,55337 \times 10^9$ ± $3,58864 \times 10^8$	+8,07
Leituras aleatórias Armazenamento	Duração	s	0,0191 ± 0,0001	0,0375 ± 0,0033	+96,40
Leituras aleatórias Armazenamento	Taxa	operações/s	523561,3607 ± 2590,4168	266577,6083 ± 23667,6871	-49,08
Pequenos arquivos Armazenamento	Duração	s	0,0407 ± 0,0071	0,1174 ± 0,0060	+188,63
Pequenos arquivos Armazenamento	Taxa	operações/s	50362,6170 ± 6765,4908	17448,7722 ± 924,1869	-65,35
Remoção de metadados Armazenamento	Duração	s	0,0184 ± 0,0001	0,0457 ± 0,0051	+148,00
Remoção de metadados Armazenamento	Taxa	operações/s	111186,4600 ± 430,0770	44832,8204 ± 4560,7233	-59,68
Gravação de escalares Armazenamento	Duração	s	0,0343 ± 0,0004	0,0324 ± 0,0023	-5,66
Gravação de escalares Armazenamento	Taxa	operações/s	291383,1533 ± 3261,0656	308870,0720 ± 22272,4492	+6,00
Checkpoint de controle Armazenamento	Duração	s	0,0536 ± 0,0054	0,1614 ± 0,0197	+200,85
Checkpoint de controle Armazenamento	Taxa	bytes/s	$2,50233 \times 10^9$ ± $2,13619 \times 10^8$	$8,31758 \times 10^8$ ± $8,44184 \times 10^7$	-66,76

4.3 Checkpoints dos modelos

Nos checkpoints do PyTorch, a gravação com sincronização persistente apresentou aumento de 59,52% no caso associado à CPU, passando de 0,0224 s para 0,0357 s. No caso associado à GPU, o aumento foi de 49,30%, de 0,0266 s para 0,0397 s. A leitura desses checkpoints apresentou aumentos de 30,77% e 31,76%, respectivamente.

Na variante sem sincronização persistente, os casos de leitura do PyTorch apresentaram aumentos de 20,43% em CPU e 2,99% em GPU. A gravação nessa variante apresentou reduções de 45,31% e 35,34%, respectivamente. No TensorFlow, as variantes correspondentes apresentaram reduções tanto na leitura quanto na gravação, conforme a Tabela 6.

A distinção entre variantes é necessária porque uma gravação concluída após a entrega ao sistema operacional e uma gravação sincronizada com o armazenamento representam fronteiras diferentes de conclusão. As diferenças entre elas não devem ser tratadas como repetições de uma única operação.

Tabela 6: Checkpoints dos modelos. Três observações por métrica e condição. Vermelho indica piora e verde indica melhora em relação ao baseline (sem).

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
Checkpoint de modelo PyTorch, CPU Sem sincronização persistente	Gravação	s	0,0202 ± 0,0026	0,0111 ± 0,0007	-45,31
Checkpoint de modelo PyTorch, CPU Sem sincronização persistente	Leitura	s	0,0085 ± 0,0012	0,0102 ± 0,0007	+20,43
Checkpoint de modelo PyTorch, CPU Persistente	Gravação	s	0,0224 ± 0,0001	0,0357 ± 0,0065	+59,52
Checkpoint de modelo PyTorch, CPU Persistente	Leitura	s	0,0086 ± 0,0004	0,0112 ± 0,0017	+30,77
Checkpoint de modelo TensorFlow, CPU Sem sincronização persistente	Gravação	s	0,0670 ± 0,0022	0,0442 ± 0,0004	-34,03
Checkpoint de modelo TensorFlow, CPU Sem sincronização persistente	Leitura	s	0,0198 ± 0,0006	0,0150 ± 0,0009	-24,22
Checkpoint de modelo TensorFlow, CPU Persistente	Gravação	s	0,0878 ± 0,0185	0,0726 ± 0,0232	-17,32
Checkpoint de modelo TensorFlow, CPU Persistente	Leitura	s	0,0220 ± 0,0056	0,0153 ± 0,0012	-30,49
Checkpoint de modelo PyTorch, GPU† Sem sincronização persistente	Gravação	s	0,0216 ± 0,0005	0,0140 ± 0,0044	-35,34
Checkpoint de modelo PyTorch, GPU† Sem sincronização persistente	Leitura	s	0,0079 ± 0,0004	0,0081 ± 0,0018	+2,99
Checkpoint de modelo PyTorch, GPU† Persistente	Gravação	s	0,0266 ± 0,0001	0,0397 ± 0,0100	+49,30
Checkpoint de modelo PyTorch, GPU† Persistente	Leitura	s	0,0074 ± 0,0029	0,0097 ± 0,0017	+31,76
Checkpoint de modelo TensorFlow, GPU† Sem sincronização persistente	Gravação	s	0,1399 ± 0,0012	0,0674 ± 0,0005	-51,83

Continua na próxima página

Tabela 6 – continuação

Carga	Métrica	Unidade	baseline (sem) mediana ± desvio	Protected (com) mediana ± desvio	Δ (%)
Checkpoint de modelo TensorFlow, GPU† Sem sincronização persistente	Leitura	s	0,0326 ± 0,0021	0,0197 ± 0,0002	-39,66
Checkpoint de modelo TensorFlow, GPU† Persistente	Gravação	s	0,1414 ± 0,0026	0,1056 ± 0,0064	-25,30
Checkpoint de modelo TensorFlow, GPU† Persistente	Leitura	s	0,0339 ± 0,0013	0,0193 ± 0,0012	-43,22

† A indicação de GPU identifica o dispositivo selecionado. O tempo também depende do hospedeiro, da alimentação dos dados e das condições do acelerador. Verde indica melhor desempenho observado de Protected (com), não aceleração causada pelo Bitdefender.

5 Discussão dos resultados e consumo do Bitdefender

5.1 Síntese do comportamento observado

Os resultados desfavoráveis à máquina com Bitdefender concentram a análise em três grupos: maior duração em tarefas de computação em CPU, maior tempo em etapas de inicialização e carregamento e maior custo nas operações selecionadas de armazenamento. Os resultados mais expressivos em termos relativos aparecem nas operações de pequenos arquivos, remoção de metadados e checkpoint de controle. Os tempos absolutos e a frequência com que essas operações ocorrem em uma aplicação determinam sua relevância operacional.

O aumento de duração e a redução de taxa descrevem a mesma mudança sob perspectivas diferentes quando se referem ao mesmo trabalho fixo. Não constituem duas evidências independentes de penalidade. Tampouco é adequado calcular a média dos percentuais de treinamento, importação e armazenamento como uma redução geral de desempenho, pois essas medidas representam operações, unidades e fronteiras de cronometragem diferentes.

A dispersão distingue situações com medianas próximas e situações com repetições mais variáveis. O desvio-padrão elevado na inicialização do PyTorch em Protected (com) ilustra por que o percentual isolado não descreve toda a experiência de execução. Por outro lado, diferenças de pequena magnitude, como a observada na multiplicação de matrizes em GPU, devem permanecer proporcionais à sua escala na interpretação.

As perdas observadas em pequenos arquivos, remoção de metadados e checkpoints de controle são especialmente relevantes para rotinas com muitos acessos ou gravações frequentes. Nesses casos, Protected (com) apresentou aumentos de duração de 188,63%, 148,00% e 200,85%, respectivamente. No PyTorch em CPU, o aumento de 76,48% na duração da CNN com dados gerados evidencia outro ponto de desempenho inferior. Esses resultados delimitam as tarefas de pior desempenho do ambiente protegido e orientam a avaliação crítica de seu custo operacional.

O consumo medido dos processos fornece evidência direta de demanda de recursos pelo próprio Bitdefender: em média, o equivalente a 1,42 processador lógico durante as janelas acompanhadas, com 77,14% do tempo de processamento do agente concentrado em ctc. Essa demanda permanece relevante mesmo nos ensaios em que Protected (com) termina mais rápido. O ganho total de uma máquina não demonstra ausência de custo do agente, assim como uma perda total não mede isoladamente esse custo.

5.2 Mecanismos plausíveis e alcance da interpretação

A inspeção de operações de entrada e saída e a competição por tempo de processamento constituem mecanismos plausíveis para uma solução de segurança acrescentar trabalho à execução de uma aplicação. A manipulação frequente de objetos pequenos e a persistência de checkpoints são pontos

em que uma análise adicional poderia investigar essa participação. Os resultados observados indicam tarefas de interesse para tal investigação, sem medir diretamente quanto do tempo foi consumido pela proteção.

A máquina Protected (com) e a máquina baseline (sem) diferem em geração de processador e número de núcleos. Essas diferenças afetam especialmente a interpretação dos ensaios em CPU e podem também influenciar a alimentação da GPU e o armazenamento. A presença de componentes do Bitdefender em Protected (com) é uma observação distinta da confirmação do estado de todos os mecanismos de proteção. Assim, a análise sustenta a descrição de desempenho inferior nos casos selecionados dessa máquina, sem decompor a diferença entre ambientes em contribuições específicas de segurança e de plataforma.

5.3 Implicações para rotinas de trabalho e telecomunicações

Para uma rotina com múltiplas inicializações, recargas de dados ou checkpoints frequentes, os resultados selecionados apontam etapas que merecem medição específica. Uma diferença pequena por operação pode ter relevância quando a operação é repetida, mas a projeção para uma rotina completa exige conhecer sua frequência e seu encadeamento. Os percentuais apresentados não substituem essa avaliação.

Em aplicações de rádio definido por software (SDR) e telecomunicações, competição por CPU e atrasos em leitura ou gravação são hipóteses pertinentes quando o processamento e a entrada e saída compartilham recursos. As medições aqui analisadas pertencem a aprendizado de máquina e armazenamento. Portanto, sua interpretação para telecomunicações é qualitativa e não fornece valores de latência de rádio, perda de amostras ou vazão de rede.

5.4 Consumo dos processos do Bitdefender

5.4.1 Processamento durante o benchmark

Durante as execuções concluídas, os oito componentes observados do Bitdefender consumiram, em conjunto, 898,71 s de processamento nos 631,19 s de intervalos efetivamente acompanhados. A utilização média somada foi de 142,38% de um processador lógico, equivalente a aproximadamente 1,42 processador lógico ou 3,96% da capacidade lógica agregada da máquina de 36 processadores lógicos. O maior intervalo amostrado apresentou 477,97%, equivalente a aproximadamente 4,78 processadores lógicos. Esse pico é simultâneo entre componentes, não a soma de máximos individuais ocorridos em momentos diferentes.

A Tabela 7 apresenta a distribuição por componente. Cada componente teve 704 observações de memória e 563 intervalos válidos para cálculo de utilização. O componente ctc concentrou 77,14% do tempo de processamento observado do agente. Sua utilização média foi de 109,84%, com pico de 346,43%. O processo principal apresentou média de 15,80%, e o componente networkmonitor apresentou 11,48%. Portanto, o consumo observado do agente não se restringiu ao componente antimalware.

Tabela 7: Processamento dos componentes do Bitdefender durante as execuções concluídas. Utilização relativa a um processador lógico. Tempos em segundos.

Componente	Média (%)	Pico (%)	Usuário (s)	Sistema (s)	Total (s)
ctc	109,84	346,43	480,72	212,56	693,28
Principal	15,80	48,60	82,11	17,61	99,72
networkmonitor	11,48	40,68	21,95	50,48	72,43
antimalware	2,94	190,06	16,41	2,16	18,57
fanotify	2,01	164,48	3,52	9,15	12,67
kpdd	0,21	1,90	0,19	1,16	1,35
Atualização	0,08	10,88	0,44	0,09	0,53
Comunicação	0,03	3,55	0,10	0,06	0,16

5.4.2 Memória dos componentes durante o benchmark

A soma da memória residente apresentou média de 2,15 GiB e máximo amostrado de 2,31 GiB. Os maiores consumidores médios foram antimalware e ctc, com 1013,15 MiB e 791,30 MiB, respectivamente. O componente antimalware atingiu 1145,69 MiB, enquanto ctc atingiu 816,57 MiB. A Tabela 8 apresenta os valores por componente. A soma de memória residente pode contar páginas compartilhadas mais de uma vez e, por isso, não equivale à memória privada exclusiva do agente.

Tabela 8: Memória residente dos componentes nas execuções concluídas. Valores em MiB.

Componente	Média	Máximo amostrado
antimalware	1013,15	1145,69
ctc	791,30	816,57
Principal	196,89	202,53
Atualização	119,92	119,92
Comunicação	31,18	31,18
fanotify	21,71	21,72
networkmonitor	18,73	18,73
kpdd	8,91	8,91

5.4.3 Variação temporal nas observações históricas

O monitoramento histórico apresentou utilização média ponderada de 44,29% de um processador lógico. O pico registrado foi de 553,41%, equivalente a aproximadamente 5,53 processadores lógicos ou 15,37% da capacidade lógica agregada. A Tabela 9 evidencia a variação entre as cinco janelas. A média de 8,94% na janela iniciada às 10h47 de 7 de outubro e a média de 65,04% na janela iniciada às 15h38 de 28 de outubro indicam condições de atividade diferentes.

Essas janelas incluem períodos associados a restrições de recursos na investigação anterior. Por isso, caracterizam as condições observadas em cada janela e não uma média diária ou uma referência uniforme sem restrições. A média histórica de 44,29% e a média de 142,38% durante o benchmark correspondem a períodos e cargas distintos. Sua diferença não foi utilizada para estimar um efeito causal do treinamento sobre o consumo do agente.

Tabela 9: Janelas históricas de monitoramento em 2026, no horário de Brasília. Memória em GiB e duração efetivamente amostrada em minutos.

Janela	Amostras	Duração	Média (%)	Pico (%)	Residente	Serviço
07/10, 10h00	8	0,27	23,65	32,86	2,66	11,85
07/10, 10h12	359	12,32	13,22	517,46	2,66	11,85
07/10, 10h47	31	1,06	8,94	14,92	3,22	12,35
28/10, 15h38	557	19,50	65,04	553,41	2,96	6,93
28/10, 16h03	107	3,66	50,16	51,90	3,03	6,94

5.4.4 Serviços, memória contabilizada e atividade de disco

O serviço principal, que reúne o processo principal e seus módulos, respondeu pela maior parte do processamento histórico: média de 44,15%, frente a 0,12% do serviço de atualização e 0,02% do serviço de comunicação. A Tabela 10 apresenta essas medidas e os volumes de leitura e gravação. Os picos individuais dos serviços não devem ser somados para reconstruir um pico conjunto.

A memória contabilizada média dos três serviços foi de 8,79 GiB, enquanto a soma média da memória residente dos processos foi de 2,87 GiB. Entre as categorias contabilizadas, as médias foram de 2,36 GiB de memória anônima, 4,56 GiB de cache de arquivos e 1,78 GiB de estruturas recuperáveis do kernel. Essas categorias descrevem dimensões distintas da memória. Cache e estruturas recuperáveis

Tabela 10: Métricas históricas por serviço. A utilização de CPU é relativa a um processador lógico.

Serviço	CPU média (%)	CPU pico (%)	Memória média (GiB)	Leitura (MiB)	Gravação (MiB)
Principal e módulos	44,15	553,13	8,21	76,55	15,04
Atualização	0,12	0,23	0,53	0,00	0,14
Comunicação	0,02	1,31	0,05	0,00	1,20

não devem ser apresentados como memória privada irrecuperável, e a soma residente não deve ser adicionada à memória contabilizada por serviço.

A atividade histórica acumulada foi de 76,55 MiB de leitura e 16,38 MiB de gravação. Os maiores intervalos de taxa apresentaram 6675,09 KiB/s de leitura e 403,61 KiB/s de gravação. A janela de 28 de outubro iniciada às 15h38 concentrou 76,51 MiB das leituras observadas. Esses volumes representam transferências contabilizadas nos serviços, sem identificar quais acessos de aplicações foram inspecionados. Leituras atendidas pelo cache podem ocorrer sem novas leituras físicas.

Nas observações contemporâneas do benchmark, os contadores de entrada e saída por processo do agente estavam indisponíveis. Assim, a atividade histórica de disco não foi transferida para a campanha de 3 de novembro, e a ausência de contadores por processo não foi tratada como consumo nulo. A combinação das duas escalas caracteriza a demanda de processamento e memória dos componentes.

6 Conclusão

Este relatório caracterizou diferenças de desempenho entre baseline (sem Bitdefender) e Protected (com Bitdefender), contemplando pioras e melhoras nas tarefas analisadas. A contribuição da análise está em separar inicialização, computação, carregamento e persistência e caracterizar o consumo dos componentes do Bitdefender, apresentando valores absolutos e dispersão em conjunto com as diferenças relativas.

Entre os resultados selecionados, a manipulação de pequenos arquivos apresentou aumento de duração de 188,63%, a remoção de metadados apresentou 148,00% e o checkpoint de controle apresentou 200,85%. No treinamento da CNN em CPU com PyTorch e dados gerados, a duração aumentou 76,48%. Esses resultados destacam as tarefas em que Protected (com) apresentou maior tempo de execução. Também ocorreram melhoras, como a redução de duração de 52,23% na CNN em GPU com TensorFlow e CIFAR-10. Durante as execuções concluídas, o agente utilizou em média o equivalente a 1,42 processador lógico, com predominância do componente ctc no tempo de processamento observado.

A implicação prática é que a avaliação de uma estação de trabalho deve considerar tanto o cálculo numérico quanto as operações que iniciam, alimentam e preservam o processamento.